

流式语音识别模型性能仿真与并发评测系统 软件功能说明书

编写人：李鲲程

编写时间：2026.1.9

目录

- 1. 软件名称 3
- 2. 软件概述 3
- 3. 软件运行环境 3
- 4. 软件输入输出说明 4
 - 4.1. 软件输入 4
 - 4.2. 软件输出 4
- 5. 软件总体功能结构 5
- 6. 主要功能模块说明 5
 - 6.1. 异构模型加载与配置模块 5
 - 6.2. 多源数据集标准化预处理模块 6
 - 6.3. 高保真流式输入仿真引擎 7
 - 6.4. 实时推理与语义优化模块 7
 - 6.5. 并发测评与负载控制模块 8
 - 6.6. 多维性能指标采集模块 9
 - 6.7. 实验数据统计与报表生成模块 9
- 7. 软件特点与创新点 10
 - 7.1. 离线流式仿真技术 10
 - 7.2. 跨架构统一评测 10
 - 7.3. 语义后处理性能损耗评估 10
 - 7.4. 高并发负载仿真 11
- 8. 软件用途 11
- 9. 结语 11

1. 软件名称

全称： 流式语音识别模型性能仿真与并发评测系统

简称： Streaming-ASR-SimBench

版本号： V1.0

2. 软件概述

本软件是一套专为实时会议语音转写场景设计的高保真性能仿真与评测平台。针对流式（Streaming）与非流式（Non-Streaming）语音识别模型在实时性要求下的差异，本系统通过构建离线流式模拟引擎，能够在不依赖物理麦克风和网络环境的情况下，精确复现真实会议中的语音流输入特征。

软件集成了 Sherpa-onnx（流式 Transducer 架构）与 Faster-Whisper（非流式 AED 架构）两大主流技术路线，并内置了基于 BERT 的准实时语义后处理模块。系统能够自动化执行单流延迟测试与多路高并发压力测试，精准采集并分析词错误率（WER）、首字上屏延迟（TTFT）及实时率（RTF）等关键效能指标，为构建低延迟、高并发的工业级会议字幕系统提供权威的量化依据。

3. 软件运行环境

操作系统：Ubuntu 20.04.6 LTS

运行环境：Python 3.12

核心算法库：

（1）深度学习框架：PyTorch 2.1+（CUDA 11.8/12.2）

(2) 模型推理: Sherpa-onnx, Faster-Whisper, ONNX Runtime
GPU

(3) NLP 处理: Transformers, DeepMultilingualPunctuation

(4) 信号处理: NumPy, SoundFile, Librosa

并发支持: Python Asyncio

硬件环境:

(1) 计算单元: 支持 CUDA 的 NVIDIA 显卡 (显存 $\geq$ 8GB)

(2) 处理器: 多核 CPU (建议 16 核以上, 用于数据加载与调度)

4. 软件输入输出说明

4.1. 软件输入

(1) 语音音频数据: 单声道, 16kHz 采样率的 WAV 文件 (如果是 FLAC 文件需要先转为 WAV 文件), 支持多数据集目录结构

(LibriSpeech、TEDLIUM、AMI 等);

(2) 文本标注数据: 数据集对应的参考文本文件

(如 .trans.txt、text.txt 等), 用于识别准确率 (WER) 计算;

(3) 模型与评测参数: 模型类型与路径配置, 音频分片长度, 并发数量。

4.2. 软件输出

软件输出结果包括:

(1) 单文件评测结果: 每条音频的识别文本, 对应的 WER、RTF、TTFT 等指标;

(2) 整体统计结果：平均错词率 (Average WER)、平均实时率 (Average RTF)、平均首字符上屏时间 (Average TTFT)；

(3) 评测日志与统计信息：控制台输出，可用于后续分析的结构化结果文件。

5. 软件总体功能结构

本软件采用分层架构设计，由数据层、仿真层、计算层与分析层构成，包含七大核心功能模块：

- (1) 异构模型加载与配置模块
- (2) 多源数据集标准化预处理模块
- (3) 高保真流式输入仿真引擎
- (4) 实时推理与语义优化模块
- (5) 并发测试与负载控制模块
- (6) 多维性能指标采集模块
- (7) 实验数据统计与报表生成模块

6. 主要功能模块说明

6.1. 异构模型加载与配置模块

功能说明：实现对不同架构语音识别模型的统一封装与参数热配置，屏蔽底层推理差异。

详细功能：

(1) 架构适配：同时支持 Transducer (Zipformer) 流式架构与 Attention-Encoder-Decoder (Whisper) 非流式架构的加载。

(2) 计算设备路由：自动检测硬件环境，支持在 CPU 集群与 GPU 显卡之间动态分配推理任务，支持 FP16/INT8 量化模式切换。

(3) 解码策略配置：提供可视化的参数配置接口，支持调节 Greedy Search (贪婪解码) 与 Beam Search (束搜索) 的宽度，以及 VAD (语音活动检测) 的阈值参数。

6.2. 多源数据集标准化预处理模块

功能说明：负责对 LibriSpeech、TEDLIUM、AMI 等主流公开数据集进行清洗与格式归一化。

详细功能：

(1) 音频重采样与归一化：自动遍历数据集目录，将不同采样率的音频统一转换为 16kHz, 16-bit/Float32 单声道 格式，确保声学特征提取的一致性。

(2) 文本清洗 (Text Normalization)：针对 WER 评测需求，内置文本标准化引擎，支持去除标点符号、统一转小写、数字转英文单词、去除语气词等操作，消除参考文本格式差异带来的评测误差。

(3) 数据集索引构建：自动生成包含文件路径、音频时长、对应的逐字稿 (Verbatim Transcript) 的元数据索引文件。

6.3. 高保真流式输入仿真引擎

功能说明：这是本系统的核心模块，用于在离线环境下“仿真”真实的实时语音流输入。

详细功能：

（1）序列化分片机制：能够将长音频文件按设定的时间粒度（如 0.1s 或 1.0s）进行逻辑切分，生成连续的数据包序列。

（2）时序同步控制（RTF=1.0）：内置高精度计时器，强制控制音频分片的发送/读取速率严格等同于音频的物理时长。例如，推送 10 秒的音频片段，系统会严格耗时 10 秒完成推送，从而精准模拟真实说话人的语速。

（3）滑动窗口模拟：针对非流式模型，支持配置重叠率与步长，模拟工业界常用的“滑动窗口”补救策略，以评估其对截断问题的改善效果。

6.4. 实时推理与语义优化模块

功能说明：执行核心的 ASR 解码以及基于 BERT 的语义后处理。

详细功能：

（1）流式状态维护：对于 Sherpa-onnx 模型，模块在内存中维护解码器的内部状态（Internal State），实现跨分片的连续识别，无需重复计算历史音频。

（2）双流语义后处理：集成 BERT 标点恢复模型，实现**“节流刷新”策略（控制高频推理，降低 GPU 负载）与“端点定稿”**策

略（利用 VAD 检测句尾，触发高精度标点修正），输出具备可读性的规范文本。

（3）正则修正兜底：内置针对英文场景的正则表达式引擎，自动修正句首大写及特定代词（如 “I”）的格式错误。

6.5. 并发测评与负载控制模块

功能说明：该模块通过维护多个并行的识别上下文（Context），在单进程内模拟多路会议同时进行的负载场景，以评估模型在极限状态下的吞吐能力。

详细功能：

（1）并发任务队列管理：实现了基于 Deque（双端队列）的待测任务池，自动扫描并加载待评测的音频文件列表，确保测试任务能够连续不断地分发给计算单元。

（2）多路流状态并行维护：采用**“工位池（Worker Slot）”**机制，在内存中同时实例化多个（如 50 个）独立的解码器流对象。系统实时维护每一路流的内部状态、音频游标位置及解码进度，模拟多用户同时在线的场景。

（3）轮询式推理调度（Round-Robin Scheduling）：核心调度引擎采用轮询机制，在主循环中依次遍历所有活跃的工位，按时间步长向模型馈送数据并触发推理。这种机制在不依赖复杂中间件的情况下，有效模拟了高并发环境下的计算负载。

(4) 极限压力配置：支持自定义并发路数（Concurrent Streams）参数。系统根据该参数自动扩展工位池大小，通过增加并行流的数量来压测 GPU 显存极限和计算算力的饱和度。

6.6. 多维性能指标采集模块

功能说明：在仿真运行过程中，实时采集并计算关键性能指标。

详细功能：

(1) 首字上屏延迟（TTFT）监测：毫秒级记录从音频分片发出到收到第一个识别字符的时间差，量化系统的“跟手度”与交互体验。

(2) 词错误率（WER）实时计算：集成 Levenshtein Distance 算法，实时对比识别结果与参考文本，统计替换、删除、插入错误率。

(3) 实时率（RTF）统计：记录纯计算耗时与音频时长的比例，评估系统的计算效率与资源占用情况。

6.7. 实验数据统计与报表生成模块

功能说明：该模块负责对评测过程中产生的原始流式数据进行实时聚合、统计计算与结构化输出。

详细功能：

(1) 多维指标聚合：在评测结束后，自动聚合所有测试用例的 WER、RTF、TTFT 数据，计算全局平均值（Average），以量化系统的长尾性能表现。

(2) 结构化报表导出：支持将详细的评测日志（包含文件名、时长、各阶段耗时、识别文本等）序列化为 CSV（Comma-Separated

Values) 或 TXT 格式文件, 便于后续导入 Excel 或其他工具进行二次分析。

(3) 控制台交互输出: 在终端实时打印评测进度与简报, 以格式化表格的形式展示当前处理文件的性能指标, 提供清晰的实验过程反馈。

(4) 对比差异分析: 支持计算并输出“基准模型”与“实验模型”在关键指标上的数值差异(如: 延迟降低了多少毫秒, RTF 提升了多少百分比)。

7. 软件特点与创新点

7.1. 离线流式仿真技术

创新性地提出了“基于序列化分片的离线流式模拟方法”。无需复杂的物理录音环境, 即可在单机上通过软件逻辑精准复现真实会议的流式输入特征, 既保证了评测的实时性, 又消除了网络波动带来的实验误差。

7.2. 跨架构统一评测

构建了兼容“有状态流式模型”与“无状态分片模型”的统一评测底座, 使得工业界两类截然不同的技术路线(Transducer vs AED)能够在完全相同的延迟约束和硬件条件下进行公平的定量对比。

7.3. 语义后处理性能损耗评估

本系统集成可配置的语义后处理组件, 用于对识别结果进行格式规范与可读性优化。区别于传统仅测试声学识别率的工具, 本系统支

持在评测过程中动态开启或关闭标点恢复与格式修正功能，并能自动统计开启该功能后对系统首字延迟（TTFT）及实时率（RTF）产生的具体耗时增量。这一特性填补了现有工具无法量化“语义优化计算开销”的空白，为用户评估系统资源占用提供了精确的数值依据。

7.4. 高并发负载仿真

内置了基于多流轮询（Multi-stream Polling）机制的负载仿真引擎。通过工位池（Worker Slot）技术，软件能够在单进程内模拟 GPU 满载状态下的极限吞吐场景，有效验证模型在高并发压力下的显存稳定性与响应延迟抖动。

8. 软件用途

（1）模型选型验证：帮助开发人员在 Whisper、Sherpa 等开源模型中，根据具体的延迟与精度指标，快速筛选出最适合业务场景的方案。

（2）算法性能基准测试：为语音识别算法研究提供标准化的实验工具，支持 WER、RTF、TTFT 等核心指标的自动化复现与对比。

（3）系统容量规划：通过并发压测功能，帮助运维人员评估单台服务器能支撑的最大会议路数，为硬件采购提供数据参考。

9. 结语

《流式语音识别模型性能仿真与并发评测系统》通过标准化的设计与创新的仿真技术，成功解决了实时语音转写场景下模型评测难、

指标不统一的问题。它不仅是一个高效的跑分工具，更是连接学术算法与工程落地的桥梁，为构建低延迟、高可用的实时会议同传系统提供了可靠的数据支撑。